Mineração de dados

Z-Score: Técnica de Detecção de Outliers

Pesquisa sobre Fundamentos, Aplicações e Demonstração Prática

Arthur Karnas, Ana Laura, Erik, Filipe Colla, João Gabriel,
José Eduardo, Juan, Kaue, Marco Antonio

O que é o Z-Score?

O Z-Score mede quantos desvios padrão um valor está acima ou abaixo da média de um conjunto de dados. Ele é usado para identificar outliers, ou seja, valores que se desviam significativamente do padrão esperado.

Fórmula Matemática

$$Z = (X - \mu) / \sigma$$

X = o valor individual que está sendo avaliado
μ (mu) = a média aritmética do conjunto de dados
σ (sigma) = o desvio padrão do conjunto de dados

Como funciona

O Z-Score padroniza os dados para uma escala com média 0 e desvio padrão 1, permitindo comparações entre diferentes conjuntos

Z-Score = 0: o valor é exatamente igual à média
Z-Score positivo: o valor está acima da média
Z-Score negativo: o valor está abaixo da média
Z-Score > 2: o valor está a mais de 2 desvios padrão da média (possível outlier)
Z-Score > 3: o valor está a mais de 3 desvios padrão da média (possível outlier)

O Z-Score está ligado à distribuição normal, onde a maioria dos dados se concentra perto da média; valores com $|Z| > 3$ são raros (≈0,27%) e geralmente considerados outliers.

68,27% dos dados estão dentro de ±1 desvio padrão da média
95,45% dos dados estão dentro de ±2 desvios padrão da média
99,73% dos dados estão dentro de ±3 desvios padrão da média

Vantagens

Simples, rápido, padroniza dados, fácil de implementar, bom para detecção inicial de outliers e comparações entre diferentes escalas.

Desvantagens

depende da normalidade, sensível a valores extremos, perde eficiência em dados pequenos, não capta bem padrões complexos ou relações entre múltiplas variáveis.

Contexto Histórico e Evolução

Antes da estatística formal, outliers eram identificados de forma visual e subjetiva, até surgirem métodos mais rigorosos no século XIX, como o Z-Score.

Francis Galton contribuiu com conceitos como regressão à média, ajudando a entender o comportamento de valores extremos.

Karl Pearson formalizou o uso do desvio padrão, tornando possível calcular o Z-Score de forma matemática e objetiva.

Com a era da computação, o Z-Score se popularizou na análise de dados e inspirou técnicas mais avançadas de detecção de anomalias.

Aplicabilidade e casos de uso

Saúde: O Z-Score ajuda a identificar valores anormais em exames e sinais vitais, auxiliando no diagnóstico e monitoramento de pacientes.

Mercado financeiro: É usado para detectar fraudes e analisar riscos, destacando transações ou empresas fora do padrão esperado.

Indústrias e Manufatura: Permite o controle de qualidade ao identificar produtos fora das especificações antes de chegarem ao consumidor.

E-Commerce: Ajuda a detectar comportamentos de compra incomuns, prevenindo fraudes e analisando padrões de consumo.

Trânsito e Transporte: É aplicado para identificar anomalias no tráfego, como velocidades ou volumes de veículos fora do normal.

Consequências: A falta de detecção de outliers pode gerar erros em modelos, fraudes, diagnósticos incorretos e decisões prejudicadas.

O tema no mercado de trabalho

Importância: O Z-Score e a detecção de outliers são essenciais para garantir a qualidade dos dados e a confiabilidade das análises, sendo habilidades fundamentais para profissionais de dados.

Requisitos: O mercado exige conhecimento em estatística, tratamento de outliers, pré-processamento e ferramentas como Python (NumPy, Pandas) e análise exploratória.

Indústrias e Manufatura: Permite o controle de qualidade ao identificar produtos fora das especificações antes de chegarem ao consumidor.

Entrevistas: Dominar quando e como usar o Z-Score (e alternativas) é um diferencial, pois demonstra conhecimento prático e teórico em análise de dados.

PYTHON

Demonstração Prática

Referências

ESTATÍSTICA FÁCIL. O que é: Z-Score Outlier Detection (Detecção de Outliers com Z-Score). Disponível em: https://estatisticafacil.org/glossario/o-que-e-z-score-outlier-detection-deteccao-de-outliers-com-z-score/

GEEKSFORGEEKS. Z score for Outlier Detection - Python. Disponível em: https://www.geeksforgeeks.org/machine-learning/z-score-for-outlier-detection-python/

DATACAMP. Z-Score: The Complete Guide to Statistical Standardization. Disponível em: https://www.datacamp.com/tutorial/z-score

PORTAL DATA SCIENCE. Como identificar Outlier nos seus dados? Disponível em: https://portaldatascience.com/outlier/

C-SUITE. Detecção e Tratamento de Outliers (Anomalias): Z-Score, Intervalo Interquartil (IQR), Filtros de Hampel. Disponível em: https://c-suite.com.br/deteccao-e-tratamento-de-outliers-anomalias-z-score-intervalo-interquartil-iqr-filtros-de-hampel/

MEDIUM – Gabriel Pastega. Outliers: Como definir, detectar e tratar — Parte 2. Disponível em: https://medium.com/@gabrielpbreis/outliers-como-definir-detectar-e-tratar-parte-2-5240149f8f98

FASTER CAPITAL. Outliers: Detecting Outliers Using Z Scores: A Statistical Approach. Disponível em: https://fastercapital.com/content/Outliers--Detecting-Outliers-Using-Z-Scores--A-Statistical-Approach.html

WIKIPEDIA. Karl Pearson. Disponível em: https://en.wikipedia.org/wiki/Karl_Pearson

WIKIPEDIA. Francis Galton. Disponível em: https://en.wikipedia.org/wiki/Francis_Galton

RODRIGUES, Francisco. Uma breve história da estatística. Medium, 2025. Disponível em: https://francisco-rodrigues.medium.com/uma-breve-história-da-estatística-8a8b0459fd10